



KARI-NA
Response Innovation

전화를 걸면, AI가 먼저 듣고 준비합니다
– 개인정보는 건드리지 않고, 인터넷 없이.

Kiwoom Academy Response Innovation · No ARS

K7팀 · 금융 콜센터 혁신 2026. 07. 29 · **15분** 발표 **김설빈**

영상

착오송금

40~50초 · 로컬 재생

웃기지만, 하루에도 수천 건 실제로 벌어지는 일입니다.

그리고 이런 일이 생기면 우리가 할 수 있는 건 딱 하나 – 은행 콜센터에 전화하는 것.

고객이 만나는 첫 벽

1번, 2번, 3번... 그래서 몇 번이죠?

원하는 항목은 끝내 나오지 않고,
다시 처음 메뉴로 돌아온다.

1 예금·적금 조회

2 대출 상담

3 카드 분실 신고

4 외환·송금

5 인터넷뱅킹 문의

6 기타 문의

· · · · · ·

0 상담원 연결

겨우 연결되면

상담사는 내가 왜 전화했는지 하나도 모른 채 시작한다.

고객

ARS를 헤매고, 연결되면 처음부터 재설명. 부서가 바뀔 때마다 또 재설명 – 긴급 상황일수록 치명적.

상담사

사전 정보 0에서 화난 고객 응대. 상황 파악 · 매뉴얼 검색 · 오연결 재이관 · 후처리(ACW) 부담.

회사

AHT↑ · 재이관율↑ · 상담사별 품질 편차↑ · 1인당 처리 콜↓.

근거 – 콜센터 현직자 인터뷰(2026-07-13): 후처리·오연결·반복설명·품질편차가 실제 병목으로 확인됨

그런데 진짜 벽은 세 번째

계좌번호, 주민번호, 인증번호. 남의 클라우드 AI에 그대로 넘겨도 될까요?

은행 입장에선 절대 안 됩니다. 그래서 못 씁니다.

이것이 은행이 AI를 쉽게 도입하지 못하는 진짜 이유입니다.

서비스 이름

KARI-NA

Kiwoom Academy

Response Innovation

No ARS

버튼 트리를 아예 없앴습니다.

고객은 그냥 평소처럼 말만 하면 됩니다.

AI가 실시간으로 알아듣고 – 용건을 요약하고, 부서를 정하고,
위험한 상황인지까지 분석해서 상담사가 전화를 받기도 전에 화면에
띄웁니다.

기다리는 콜센터 → 준비되는 콜센터



AI는 상담사를 대체하지 않습니다 — 최종 판단·인증·사고 조치는 언제나 사람이 합니다.

무대 액션

지금, 인터넷 선을 뽑겠습니다.

이제부터 보시는 건 전부 이 방 안에서만 됩니다.

음성 인식도, 언어모델도, 감정 분석도, 규정 검색도 – 전부 이 안에.

클라우드 호출 **0번**

글꼴까지 로컬 – 아무것도 안 깨짐

라이브 데모 · 5분

전화 한 통이, 눈앞에서 처리됩니다.

시나리오 – 착오송금. 방금 영상 속 그
고객이 되어, 동료가 실제로 전화를 겁니다.

고객 휴대폰

상담사 콘솔

관제 대시보드

라이브



실제 화면으로 전환

방금, 이 일곱 가지가 일어났습니다

무슨 일	화면	핵심
① 통화 시작	연결 · 파형이 움직임	인터넷 없이 마이크가 로컬로
② 고객이 문의를 말함	실시간 자막	버튼 0번 – 말만 했는데 알아듣는다
③ 계좌번호를 말로 부름	자막에서 즉시 ●●● 마스킹	AI가 받는 글자부터 이미 가려짐
④ AI 처리	사전요약 + 계좌보안팀 배정	상담사가 받기 전에 맥락이 준비됨
⑤ 유의사항 카드	착오송금 반환청구 절차	환각 아님 – 실물 규정에서 검색
⑥ 본인인증	요청이 :8100 으로	격리 서버 – AI는 접근 불가
⑦ 통화 종료	후처리 요약 자동 작성	상담사는 확인·보정만

방금 그 3초 안에

다섯 개의 AI 모델이 이 노트북 한 대에서 동시에 돌아왔습니다.

음성 → 글자

내용 요약


감정 측정

부서 분류

규정 검색

이게 "AI 좀 써봤어요"와 "AI 파이프라인을 운영합니다"의 차이입니다.
그리고 이 전부가 – 클라우드 호출 0번.

이게 어떻게 도는가



➔ 인터넷(WAN) 없음 · 외부 호출 0

전용 공유기 폐쇄망, 모델은 현장 전 로컬에 미리 내려받음.

개인정보 서버는 인증 성공 후에만 열리고,
AI 서버에는 여기 접근 코드가 0줄.

전부 오픈소스 · 로컬 모델 – 클라우드 종속 0

레이어	무엇으로	역할 · 실측
STT	faster-whisper large-v3-turbo	한국어 음성 → 텍스트 (로컬 GPU)
언어모델	EXAONE 3.5 7.8B · Ollama	요약 · 부서분류 · 위험판단 LG 한국어 특화, 로컬
감정온도	eGeMAPS 88 + LightGBM	음성 격양도 참고 신호 · Macro-F1 0.564 · 14MB CPU
음성분노	WavLM 층융합 + MLP	'냉정한 분노' 보조 Macro-F1 0.805 · GPU 조건부
라우팅	규칙 + scikit-learn	단순 / 일반 / 사고 3단계 + 부서 분류
RAG	bge-m3(1024d) + 로컬 벡터검색	실물 규정 1,563 청크 · 7 분야 검색
개인정보	규칙 11종 + pii-service	실시간 마스킹 + 별도 서버 격리
프론트 · 백	React 18 · Vite / FastAPI	실시간 자막 · 카드 / WebSocket 스트리밍 폰트 동봉 → 오프라인 OK

26,635

코드 줄 수

111

테스트 전부 통과

11

건

설계 결정 기록(ADR)

0

외부 인터넷 호출

kda4-k7-product/ ← 프론트·백엔드 한 저장소로 단일화

- └ **src/** React 18 · Vite · TS
- └ **backend/** FastAPI · WebSocket · 파이프라인
 - └ services/ STT · 감정 · 라우팅 · RAG · **pii_guard**
- └ **pii-service/** 개인정보 격리 서버 (별도 프로세스)
- └ **docs/** · **ADR ×11** 왜 이렇게 만들었나

저장소를 하나로 합쳤습니다

프론트·백엔드가 흩어져 있던 걸 **모노레포**로 단일화 – 버전이 엇갈리지 않고, 팀원 누구나 통째로 받아 바로 돌립니다.

실물 규정 코퍼스

1,563

청크

실제 은행 약관 · 공개 금융 규정에서
가져온 **진짜 문서**입니다.

7개 분야

예금

대출

외환

연금

전자금융

카드

사고신고

근거가 없으면
차라리 비웁니다.

없는 얘기를 지어내지 않습니다. 화면의 절차는 전부 검색된 원문으로 되짚을 수 있습니다.

한 겹이 아니라 네 겹으로 막습니다

● 라이브

● 실서비스 설계

1 실시간 마스킹 11종

말이 글자가 되는 즉시 계좌·주민·카드번호를 가림. AI가 받는 전사부터 이미 가려져 있음.

● 라이브

2 개인정보 격리 – pii-service

계좌 원문·인증값은 별도 프로세스·별도 저장소에. AI 백엔드 코드엔 이 서버 참조가 0줄.

● 라이브

3 서비스 간 mTLS · 사설 PKI

서비스끼리 상호 인증서 검증 + 암호화, 자체 사설 CA 발급, allowlist 기반. ADR로 설계 문서화 – 데모는 로컬 HTTP.

● 설계

4 완전 망분리 – 온프레미스

외부 인터넷 호출 0건. 랜선을 뽑아 눈앞에서 증명. 데이터가 나갈 경로 자체가 없음.

● 라이브

1층 - 전사되는 즉시

AI는 애초에 가려진 글자만 봅니다

계좌번호

전화번호

주민등록번호

카드번호

여권번호

운전면허번호

사업자등록번호

생년월일

인증번호 · OTP · 비밀번호

이메일

이름

상당사도, AI도 원문을 못 봅니다. 심표를 끼워
넣는 우회 입력까지 테스트로 발견해 막았습니다.

2층 - 구조로 막는다

진짜 개인정보는 **AI가 접근조차 못 하는 곳에** 있습니다

AI 백엔드

:8000 · 대화 내용만
STT · 요약 · 라우팅 · RAG

코드 0줄

pii-service

:8100 · 별도 프로세스
계좌 원문 · 인증값 · 자체 저장소

AI 서버 코드에는 이 주소가 단 한 줄도 없습니다.
인증에 성공한 상담사 화면만 문을 엽니다.

과장하지 않겠습니다

실제로 동작합니다

- 실시간 통화 · 스트리밍 전사
- 완전 온프레미스 (외부 호출 0)
- 개인정보 마스킹 · 격리 서버
- 업무 분류 · 부서 라우팅
- 실물 규정 검색 (RAG)
- 통화 후처리 자동 요약

이번 범위 밖입니다

- 실제 은행 코어망 연동
- 실제 전화망(CTI/SIP) 연결
- 지급정지 · 원장 조회 실행
- 데모 데이터는 전부 가상

감정온도 · 음성분노는 자동 판단이 아니라
상담사 참고 신호입니다 – 오남용 방지 설계.

그리고 사투리

"해결했습니다"가 아니라 "측정했습니다."

직접 조사해보니 바로 갖다 쓸 온프레미스 방언 모델이 업계에 없었습니다.
유일한 길인 파인튜닝은 데이터 승인·학습 시간 때문에 이번 발표까진
무리였습니다.

그래서 근거 없이 부풀리는 대신 **측정된 한계 + 로드맵**으로 가져왔습니다.
다음은 방언 데이터 확보 → 파인튜닝, 실시간 위험 신호 고도화, 규정집 전체
연동입니다.

AI가 점점 앞으로옵니다

01 · 현재

통화 전 준비

접수 요약 → 준비카드. 상담사가 맥락을 갖고 시작한다.

02

통화 중 동행

스트리밍 요약 · 감정온도 실시간 · 방언 STT.

03

선제 제안

"이 문의의 다음 질문은 87%가 서류" – 묻기 전에 카드를 낸다.

04 · 비전

1차 응대 AI

단순 문의는 AI가, 사람은 감독과 복잡 케이스.
로컬 실시간 음성 모델 성숙 시.

각 단계가 이전 단계의 데이터를 먹고 자랍니다 – 쓸수록 똑똑해지는 콜센터.

한 문장으로

고객은 말만 하고,
AI는 준비하고,
개인정보는 건물을 나가지 않습니다.

저희는 "만들겠습니다"를 설명하러 온 게 아니라,
"이미 돌아갑니다"를 보여드리러 왔습니다.



KARI-NA
Response Innovation

감사합니다.

인터넷 없이도, 개인정보를 지키면서,
상담을 더 빠르고 정확하게.

K7팀 · 2026. 07. 29
Kiwoom Academy Response Innovation · No ARS